выбор лучшей идеи

Вообщем-то все идеи кажутся сильными и судя по рассмотренным похожим работам, они могут показать хороший прирост метрик и решить задачу генерации сложных семантик. Однако, что для идеи дообучения рефайнора и энкодера, что для идеи дообучения lora версии для ранних латентов, мы не нашли подходящие датасеты. Таким образом самой реалистичной идеей для нас стал vlm guidance.

план проверки за 2-4 недели: Идея 2 (vlm guidance)

тз структуры плана:

1. Какой минимальный экспериментальный сетап вам нужен (модель, данные, метрики).
2. Определите, какие бейзлайны вам будут нужны в этом эксперименте. Опишите, какую реализацию этих бейзлайнов вы будете использовать.
3. Определите, какой код вы будете использовать для реализации этого эксперимента (свой, код авторов, другие варианты).
4. Напишите, какие результаты вы ожидаете от этого эксперимента. Какие метрики или другие характеристики метода должны улучшиться, насколько сильно.
5. Опишите sanity check эксперименты, по которым вы проверите, что ваша реализация кода корректна. Напишите какое поведение вы ожидаете от этих экспериментов, чтобы потом проверить это на практике.
6. Напише критерии успеха/неуспеха этого эксперимента. В каком случае нужно нужно будет отказываться от этой идеи, а в каком развивать ее дальше.

1 (модель, данные, метрики):

модели:

- диффузиока: 👈 Илья, как думаешь, какую выбрать?
  - FLUX.2-klein-4b-nvfp4 (huggingface) — денойз за 4 шага, можно считать честные градиенты, но не как в статье
  - stable-diffusion-v1-4 (huggingface) — как в статье ND (arxiv), но денойз за 50 шагов и градиенты считали приближенно
- guiding VLM:
  - CLIP-FlanT5-11B (huggingface) — как в статье ND (arxiv), она себя там зарекомендовала

Метрикки:

- CLIP score с помощью CLIP ViT-L/14 (huggingface), как в статье ND (arxiv)
  - simple_cases, complex_cases (link) — наборы промптов с простой и усложненной семантиками
- Alignment VLM оценка соответствия семпла промпту), как в статье SAP (arxiv)
  - Whoops (link), version by SAP (arxiv) authors — набор из 500 text to image промптов
  - Whoops-Hard (link), by SAP (arxiv) authors — набор из 100 сложных text to image промптов
  - ContraBench (link), by SAP (arxiv) authors — набор из 40 сложных text to image промптов

2 (бейзлайны)

1. голые модели (SD1.5, SD3.0, FLUX.1[dev], FLUX.2[dev])
2. proxy prompts × FLUX.1 — SAP (arxiv)

3 (чей код буду использовать)

мне понадобится код

- бейзлайн моделей:
  - SD1.5 — huggingface
  - SD3.0 — huggingface
  - FLUX.1 👈 какой flux.1 взять бейзлайном — куча версий и квантизаций?
  - FLUX.2 👈 какой flux.2 взять бейзлайном — куча версий и квантизаций?
  - proxy prompts — буду использовать код авторов (github)
- метрик:
  - CLIP score — буду использовать код (github) авторов статьи ND (arxiv)
  - Alignment — буду использовать код (github) авторов статьи SAP (arxiv)
- код непосредственно эксперимента я планирую написать сам, основываясь на коде авторов статьи ND (arxiv) — они реализовывали похожую идею.

4 (Ожидаемый результат)

Ожидаю, что наш пайпалайн позволит семплить out of prior изображения, а именно

- побить бейзлайны CLIP score, Alignment
- нетипичные концепты, сочетания концептов (медведь стоит на передних лапах, гриб со сломанной поплам ножкой)
- научиться работать с количествами (рука с шестью пальцами)

Основываясь на том, какой качественный прирост CLIP score получили авторы статьи ND (arxiv), по сравнению с обычной диффузионной генерацией (картинка справа), мне верится, что мы можем выбить еще более впечатляющие метрики, поскольку мы обобщаем и развиваем их метод. Допускаю, что мы можем получить CLIP score 0.5.

Так же, судя по порядку приросто метрики Alignment у авторов статьи SAP (arxiv), что разумные значения метрики 85, 62, 66 на соответствующих датасетах. Допущу что прибавить 5 ко всем этим метрикам было бы хорошо.

	Benchmarks		
Models	**Whoops**	**Whoops-Hard**	**ContraBench**
Ella	69.09	45.18	55.16
SD3.0	82.65	55.75	57.5
RGF (SD3.0)	83.50	57.06	59.16
FLUX	78.85	48.3	57.16
Ours (FLUX)	**85.10**	**62.13**	**66.16**

5 (sanity check, ожидания)

проверию

- не сломал ли наш пайплайн гайденса генерацию в целом::
  - посмотрю глазами, какие семплы выдает модель
  - сравнюсь с бейзлайнами по метрикам оценивающим генерацию простых семантик
    - CLIP score на датасете simple_cases
    - Alignment на Whoops
- научилась ли модель генерировать требуемое по “сложным” промптам
  - попробую сгенерировать свой любимый промпт: “mushroom in the forest with a leg broken in half”
  - сравнюсь с бейзлайнами по метрикам оценивающим генерацию сложных семантик
    - CLIP score на датасете complex_cases
    - Alignment на Whoops-Hard, ContraBench

хотелось бы ожидать прироста по всем метрикам и успешно сгенерированный гриб со сломанной ножкой (до сих пор ни чем мне его не удавалось сгенерировать)

6 (критерии успеха, неудачи)

Эксперимент можно будет считать успешным, если удастся получить хотябы небольшой прирост в метриках (CLIP score, Alignment). Это будет значить, что в целом идея vlm guidance подходит для задачи генерации сложных семантик, просто возможно, чтобы выбить впечатляющие метрики, надо подкрутить пайплайн гайденса.

И напротив, если у нас, что бы мы не делали с нашим пайпалайном, метрики расти не будут, значит либо мы чего-то не понимаем о том, как делать vlm guidance, либо градиенты VLM сами по себе не подходящий для нашей задачи инструмент.